

Pergunta 1:

Uma empresa de tecnologia está analisando o perfil dos usuários que assinam seu serviço premium. Ela coletou dados de 10.000 usuários e percebeu que 1.200 não informaram sua idade no cadastro. A equipe de análise quer segmentar os usuários por faixa etária para personalizar campanhas de marketing.

Se esses 1.200 usuários forem removidos, haverá uma redução significativa na amostra. Por outro lado, preenchê-los com uma média pode distorcer os grupos etários. O que um Analista de Dados deve fazer para minimizar o impacto desse problema?

☐ Preencher os valores ausentes com a idade mais comum entre os usuários, pois isso minimiza distorções

☒ Comparar as características dos usuários com idade ausente (tanto entre eles quanto com os outros usuários que preencheram as idades) e verificar se há um padrão antes de decidir como tratá-los

Correto ✓

🚀 Explique melhor

☐ Remover os usuários sem idade informada e redistribuir proporcionalmente os demais, ajustando os pesos estatísticos

☐ Assumir que os usuários sem idade informada pertencem à faixa etária majoritária da base e ajustá-los automaticamente

Pergunta 2:

Uma pesquisa analisou a relação entre renda e escolaridade e coletou respostas de 200 pessoas. Após a análise inicial, percebeu-se que 30 dessas respostas estavam incompletas, sem dados sobre escolaridade. O que um Cientista de Dados poderia fazer para lidar com essa situação da forma mais eficiente?

☐ Remover todas as 30 respostas sem escolaridade informada para evitar problemas na análise

☐ Preencher os valores ausentes com a média da escolaridade dos outros participantes

☒ Separar as respostas incompletas para testar se sua exclusão afeta os resultados finais

Correto 

✦ Explique melhor

☐ Substituir os valores ausentes por um valor fixo, como "Ensino Médio Completo"

Pergunta 3:

Uma empresa de logística criou um modelo para estimar o tempo de entrega de pacotes baseado na distância percorrida. O modelo adotado foi:

$T(d) = 0.5 \cdot d + 2$

Onde:

- d é a distância em quilômetros
- T(d) é o tempo estimado de entrega em horas

Após a implementação do modelo, foram coletados os tempos reais de entrega de 5 pacotes:

Distância (km)	Tempo Real (horas)	Tempo Estimado pelo Modelo (horas)
10	7.5	?
20	11	?
30	17	?
40	21	?
50	27	?

O Analista de Dados deseja verificar se o modelo está subestimando ou superestimando os tempos reais. Após verificar constatou que o modelo está:

-

Considere:

*Um desvio é a diferença entre o valor real (observado no mundo real) e o valor previsto por um modelo. Se esse desvio for positivo, significa que o modelo subestimou a realidade, ou seja, o valor previsto foi menor que o real. Se for negativo, significa que o modelo superestimou a realidade, ou seja, o valor previsto foi maior que o real. Se o desvio for zero, indica que o modelo previu exatamente o valor observado, o que pode sugerir que ele é adequado – embora isso precise ser analisado no contexto de todos os dados, e não apenas de um caso isolado.

**A soma dos desvios pode fornecer uma indicação inicial sobre a tendência do modelo de subestimar ou superestimar os valores reais. No entanto, como desvios positivos e negativos podem se cancelar, essa métrica sozinha não é suficiente para avaliar a qualidade do modelo. Por isso, é comum utilizar medidas como o erro médio absoluto (MAE) ou o erro quadrático médio (MSE), que consideram a magnitude dos desvios sem que eles se anulem, permitindo uma avaliação mais confiável da precisão do modelo. Entretanto, para fins didáticos deste exercício, considere apenas a soma dos desvios na sua interpretação e cálculos.

☒ **O modelo está superestimando os tempos reais de entrega. A soma dos desvios (real-previsto) é negativa, indicando que, em média, o modelo prevê tempos maiores do que os observados na prática.**

✦ Explique melhor

Correto

✓

☐ O modelo está subestimando os tempos reais de entrega. A soma dos desvios é negativa, o que indica o oposto.

Pergunta 4:

Uma empresa de tecnologia quer lançar um produto para jovens adultos e contratou um analista para estudar os hábitos de consumo de diferentes faixas etárias. No conjunto de dados coletado, 75% dos entrevistados têm entre 18 e 30 anos, e os outros 25% estão acima dessa faixa. Como o analista deve proceder para garantir que a análise seja relevante para a empresa?

☐ Focar apenas nos dados da faixa etária predominante e excluir os outros

☒ **Se a amostra foi grande, manter todos os dados e considerar diferentes análises para cada grupo. Se a amostra for pequena, considerar só o grupo mais representativo**

Correto ✓

✚ Explique melhor

☐ Ajustar os pesos dos dados para que todas as faixas etárias tenham a mesma influência

☐ Excluir as faixas etárias com menos participantes, pois distorcem os resultados

Pergunta 5:

Um estudo sobre economia coletou dados sobre o impacto da inflação na renda média da população. Ao analisar a relação entre o Índice Geral de Preços do Mercado (IGP-M) e a renda média disponível para consumo de itens não essenciais dos cidadãos nos últimos cinco anos, observou-se que, conforme o IGP-M aumentava, a renda média disponível para consumo de itens não essenciais diminuía proporcionalmente. Como essa informação pode ser útil na prática? Você manteria as duas variáveis no seu estudo?

- ☐ Para estimar o crescimento da renda a longo prazo e manteria apenas a renda média como variável dependente
- ☐ Apenas para análise descritiva, pois a relação pode ser acidental, e não manteria ambas no estudo
- ☒ Para prever o impacto da inflação na queda da demanda e sim, pois há uma relação significativa entre as variáveis Correto ✓
[🔗 Explique melhor](#)
- ☐ Para analisar a inflação isoladamente e não manteria a renda disponível para consumo, pois não há influência direta

Pergunta 6:

Uma rede de lojas aplicou um desconto de 20% em determinados produtos e quer entender se isso impactou o volume de vendas. O que um analista deve fazer para obter uma conclusão confiável?

- ☐ Verificar o total de vendas do mês e comparar com meses anteriores
- ☒ Comparar o volume de vendas antes e depois da promoção, ajustando para sazonalidade do período

Correto ✓

👉 Explique melhor

- ☐ Considerar apenas os produtos que tiveram aumento nas vendas
- ☐ Criar um gráfico mostrando o aumento percentual das vendas sem ajustes

Pergunta 7:

Uma rede de academias quer entender o perfil dos clientes mais fiéis. Para isso, analisou dados de 5.000 clientes e percebeu que:

- 40% dos clientes frequentam a academia há mais de 2 anos
- 35% frequentam há 1 a 2 anos
- 25% frequentam há menos de 1 ano

Além disso, os dados mostram que 80% dos clientes com mais de 2 anos de frequência são homens e 60% têm entre 25 e 40 anos. Com base nesses dados, a academia deseja criar campanhas para atrair clientes mais propensos a permanecer por longos períodos. Qual abordagem faz mais sentido?

☐ Criar campanhas segmentadas para homens de 25 a 40 anos, pois esse grupo já demonstrou maior fidelidade

☒ **Investir na retenção dos clientes que frequentam há menos de 1 ano, pois aumentar esse tempo pode gerar mais fidelização. Além disso, deve investir na permanência das mulheres, buscando entender e identificar o motivo das mulheres não permanecerem na academia por mais de 2 anos**

Correto ✓

✚ Explique melhor

☐ Focar exclusivamente em clientes do sexo masculino, já que representam a maioria dos clientes fiéis

☐ Direcionar campanhas apenas para novos clientes, pois os antigos já estão fidelizados

Pergunta 8:

Um analista recebeu uma planilha com informações sobre PIB, desemprego e nível de escolaridade em diferentes cidades. Ele percebeu que alguns municípios tinham dados inconsistentes, como taxas de desemprego negativas. O que ele deve fazer antes de começar a análise?

- ☐ Excluir todas as cidades com valores estranhos para evitar distorções
- ☐ Ajustar os valores negativos para zero e seguir com a análise
- ☒ **Verificar se os dados foram digitados corretamente ou se houve erro na coleta e caso não seja possível recuperar os dados, excluí-los da análise**

Correto 

🚩 **Explique melhor**

- ☐ Usar a média dos dados corretos para substituir os valores inconsistentes

Pergunta 9:

Uma empresa de entregas quer prever o tempo de entrega dos pedidos com base na distância, trânsito e condições climáticas. O que um Cientista de Dados deve fazer antes de construir um modelo preditivo?



Coletar os dados históricos e testar quais variáveis realmente impactam o tempo de entrega

Correto 

👉 Explique melhor



Criar um modelo imediato e corrigir as previsões depois, se necessário



Utilizar apenas a distância, pois é a variável mais relevante para o problema



Ajustar os tempos de entrega para valores médios, facilitando a modelagem

Pergunta 10:

Um banco quer prever a probabilidade de um cliente solicitar um empréstimo nos próximos três meses. Os dados disponíveis incluem: idade, renda mensal, tempo de conta ativa, histórico de pagamentos e número de transações por mês. Como o Cientista de Dados deve selecionar as variáveis mais relevantes?

☐ Utilizar todas as variáveis disponíveis para evitar perda de informação

☒ Inicialmente, testar a relação (podemos chamar isso de correlação) de cada variável com a solicitação de empréstimo e remover as irrelevantes

Correto ✓

✚ Explique melhor

☐ Escolher apenas idade e renda mensal, pois são as mais intuitivas para esse problema

☐ Criar uma média de todas as variáveis e usar esse valor único para prever o comportamento