

Pergunta 1:

Em um modelo de Machine Learning para previsão de fraudes bancárias, a probabilidade de um evento ser uma fraude é calculada com base em um conjunto de variáveis. O que significa dizer que um modelo atribuiu uma probabilidade de 0,85 para uma transação ser fraudulenta?

- ☐ A transação é com certeza fraudulenta
- ☐ Existe 85% de chance de a transação ser fraudulenta dado que o modelo está certo, segundo o modelo
- ☐ A transação é legítima, pois a probabilidade é menor que 1
- ☐ O modelo tem 85% de precisão geral na detecção de fraudes
- ☒ Existe 85% de chance de a transação ser fraudulenta, segundo o modelo

Correto ✓

⚡ Explique melhor

Pergunta 2:

Em um estudo sobre hábitos de leitura, um Cientista de Dados descobriu que 40% das pessoas leem livros (evento A) e 30% leem revistas (evento B). Se a probabilidade de uma pessoa ler livros ou revistas ($A \cup B$) é de 60%, qual a probabilidade de uma pessoa ler livros e revistas ($A \cap B$)?

☐ 0%

☐ 5%

☒ 10%

Correto ✓

Para calcular a probabilidade de uma pessoa ler tanto livros quanto revistas, usamos a fórmula da união de dois eventos: $P(A \cup B) = P(A) + P(B) - P(A \cap B)$. Sabemos que $P(A \cup B) = 0.60$, $P(A) = 0.40$ e $P(B) = 0.30$. Substituindo, temos $0.60 = 0.40 + 0.30 - P(A \cap B)$. Resolvendo, $P(A \cap B) = 0.10$, ou seja, a probabilidade de ler livros e revistas é 10%.

↔ Explique melhor

☐ 15%

Pergunta 3:

Um Cientista de Dados está limpando um conjunto de dados para análise de churn de clientes (taxa de atrito ou rotatividade de clientes). Ele precisa armazenar informações como idade, tempo de contrato e se o cliente cancelou o serviço (Churn).

Qual das alternativas corretamente relaciona as variáveis com seus tipos de dados?

☐ Idade (int), Tempo de contrato (string), Churn (float)

☐ Idade (float), Tempo de contrato (int), Churn (string)

☒ Idade (int), Tempo de contrato (float), Churn (bool)

Correto ✓

Correto. A idade é um número inteiro, então o tipo de dado correto é "int". O tempo de contrato pode ter valores decimais, então o tipo de dado correto é "float". "Churn" indica se o cliente cancelou ou não o serviço, o que pode ser representado por um valor booleano (verdadeiro ou falso), então o tipo de dado correto é "bool".

🚩 Explique melhor

☐ Idade (int), Tempo de contrato (int), Churn (bool)

Pergunta 4:

Um Cientista de Dados quer calcular a média de vendas mensais de uma empresa e identifica os seguintes valores para os últimos três meses (este é um código em Python com comentários - explicações):

- ```
1 | vendas = [12000, 15000, 18000] #esta é uma lista de valores contendo 3 valores e
 chamada de vendas
2 | media = sum(vendas) / len(vendas) #sum é uma função que soma o objeto passado
 nele, nesse caso os valores de vendas e len é uma função que calcula quantos
 elementos tem dentro do objeto passado nele, neste caso o objeto vendas, que
 contém 3 elementos
3 | print(media) #print é uma função que mostra na tela o que está dentro dele,
 neste caso o cálculo da média que foi realizado
```

Qual será a saída do código? (obs: tudo que está depois de "#" são comentários e é ignorado)



15000

Correto ✓

Média =  $(12000 + 15000 + 18000) / 3 = 15000$

👉 Explique melhor



18000



12000



Erro no código

Pergunta 5:

Um Analista de Dados está investigando a classificação de e-mails como spam ou não spam e analisa os seguintes eventos:

- 90 e-mails foram corretamente identificados como spam.
- 80 e-mails foram corretamente identificados como não spam.
- 10 e-mails foram incorretamente classificados como spam, quando na verdade não eram.
- 20 e-mails foram incorretamente classificados como não spam, quando na verdade eram spam.

Dado que um e-mail foi classificado como spam, qual a probabilidade de ele realmente ser spam? Essa probabilidade pode ser calculada como a razão entre o número de e-mails que são de fato spam dentro do conjunto de e-mails classificados como spam. Qual é essa probabilidade?

☐ 80%

☐ 85%

☒ 90%

Correto ✓

Para calcular essa probabilidade, é necessário dividir o número de e-mails corretamente classificados como spam pelo total de e-mails que o modelo classificou como spam. Neste caso, 90 e-mails foram corretamente identificados como spam, enquanto 10 foram classificados como spam de forma errada, totalizando 100 e-mails rotulados como spam. O cálculo é 90 dividido por 100, resultando em 0,9, ou seja, 90%. Isso significa que, se o modelo classifica um e-mail como spam, há uma chance de 90% de que essa classificação esteja correta.

⚡ Explique melhor

☐ 95%

Pergunta 6:

Uma fintech analisou um histórico de 1.000 transações bancárias e descobriu que 300 delas eram fraudes. Se uma transação for escolhida aleatoriamente, qual a probabilidade de ela não ser fraudulenta?

☐ 60%

☒ 70%

$P(\text{Não Fraude}) = 700/1000 = 0,70$  ou 70%

Correto ✓

👉 Explique melhor

☐ 80%

☐ 90%

Pergunta 7:

Em um estudo sobre a satisfação de clientes, um Cientista de Dados descobriu que 60% dos clientes estão satisfeitos com o produto (evento A) e 50% estão satisfeitos com o atendimento ao cliente (evento B). Se a probabilidade de um cliente estar satisfeito com ambos ( $A \cap B$ ) é de 30%, qual a probabilidade de um cliente estar satisfeito com o produto OU o atendimento ( $A \cup B$ )?

☐ 70%

☒ 80%

$$P(A \cup B) = 0,60 + 0,50 - 0,30 = 0,80$$

✚ Explique melhor

Correto ✓

☐ 90%

☐ 100%

Pergunta 8:

Um Cientista de Dados está desenvolvendo um algoritmo para classificar um conjunto de dados. Ele precisa garantir que o algoritmo seja eficiente e preciso. Quais das seguintes características são essenciais para um bom algoritmo?

☐ Complexidade e ambiguidade

☒ Precisão e finitude

Correto ✓

⚡ Explique melhor

☐ Subjetividade e generalidade

☐ Ineficiência e infinitude

Pergunta 9:

Na construção de um pipeline de dados (uma sequência de passos com o objetivo de mover, transformar e armazenar dados), a organização e estruturação correta dos dados são essenciais. Qual dos conceitos abaixo é fundamental para garantir a manipulação eficiente de dados em um programa de análise de dados?

☐ Ainda no pipeline o uso de variáveis com nomes curtos e genéricos para economizar memória

☒ Ainda no pipeline a escolha de tipos de dados apropriados para representar as informações com precisão

Correto ✓

Tipos de dados certos garantem que os dados sejam armazenados e processados com precisão, otimizam o uso da memória e facilitam a manipulação e análise dos dados.

✚ Explique melhor

☐ Evitar o uso de estruturas como listas e dicionários para não aumentar a complexidade do armazenamento de dados

Pergunta 10:

Em um projeto de análise de dados, um Cientista de Dados precisa armazenar a idade de clientes (números inteiros) e seus nomes (textos). Quais tipos de dados são mais adequados para essas informações?

☐ Reais e caracteres

☐ Inteiros e lógicos

☐ Caracteres e reais

☒ Inteiros e caracteres

Correto ✓

✚ Explique melhor

Pergunta 11:

Um Cientista de Dados está analisando o lançamento de três moedas. Qual a probabilidade de sair KKC?

Considerando que K = Cara e C = Coroa

☐ 10%

☒ 12,5%

Correto ✓

Quando um Cientista de Dados está analisando o lançamento de três moedas, cada moeda tem dois resultados possíveis: Cara (K) ou Coroa (C). Portanto, o número total de combinações possíveis para três moedas é  $2^3 = 8$ . As combinações possíveis são: KKK, KKC, KCK, KCC, CKK, CKC, CCK, CCC. O evento desejado é "KKC", que é uma das combinações possíveis. Assim, a probabilidade de sair KKC é a razão entre o número de resultados favoráveis (1, já que só há uma ocorrência de KKC) e o número total de resultados possíveis (8). Logo, a probabilidade de sair KKC é  $1/8$ , o que corresponde a 12,5%.

✦ Explique melhor

☐ 15%

☐ 17,5%